Московский государственный технический университет им. Н.Э. Баумана
Кафедра «Системы обработки информации и управления»

Лабораторная работа 1
по дисциплине
«Методы машинного обучения»
на тему
«Разведочный анализ данных. Исследование и визуализация данных»

Выполнил:
студент группы ИУ5-21М
Могильников И. А.

Москва — 2019 г.

1. Описание задания

Цель лабораторной работы: изучение различных методов визуализация данных.

Задание: * Выбрать набор данных (датасет). Вы можете найти список свободно распространяемых датасетов здесь. Для лабораторных работ не рекомендуется выбирать датасеты большого размера. * Создать ноутбук, который содержит следующие разделы:

1) Текстовое описание выбранного Вами набора данных.
2) Основные характеристики датасета.
3) Визуальное исследование датасета.
4) Информация о корреляции признаков.

- Сформировать отчет и разместить его в своем репозитории на github.

2. Ход выполнения лабораторной работы

2.1. 1. Текстовое описание выбранного набора данных.

Датасет представляет собой набор оценок, полученных студентами высшей школы на тестах в США по различным предметам.

2.2. 2. Основные характеристики датасета.

Категориальные характеристики:

- gender - пол
- race/ethnicity - раса/этническая принадлежность
- parental level of education - уровень образования родителей
- lunch - тип обеда, покупаемого студентом
- test preparation course - прохождение студентом специального курса по подготовке к тесту

Количественные характеристики: * math score - количество баллов по математике (максимум 100) * reading score - количество баллов по литературе (максимум 100) * writing score - количество баллов по письму (максимум 100)

2.3. 3. Визуальное исследование датасета.

2.3.1. Загрузка данных из Google Drive

In [0]:
```
!pip install -U -q PyDrive
import os
from pydrive.auth import GoogleAuth
from pydrive.drive import GoogleDrive
from google.colab import auth
from oauth2client.client import GoogleCredentials
```

In [0]:
```
# 1. Authenticate and create the PyDrive client.
auth.authenticate_user()
gauth = GoogleAuth()
gauth.credentials = GoogleCredentials.get_application_default()
drive = GoogleDrive(gauth)
```

In [0]:
```
# choose a local (colab) directory to store the data.
local_download_path = os.path.expanduser('~/data')
try:
  os.makedirs(local_download_path)
except: pass
```

In [0]:
```
# 2. Auto-iterate using the query syntax
#    https://developers.google.com/drive/v2/web/search-parameters
file_list = drive.ListFile(
    {'q': "title='StudentsPerformance.csv'"}).GetList()
```

In [7]:
```
for f in file_list:
  # 3. Create & download by id.
  print('title: %s, id: %s' % (f['title'], f['id']))
  fname = os.path.join(local_download_path, f['title'])
  print('downloading to {}'.format(fname))
  f_ = drive.CreateFile({'id': f['id']})
  f_.GetContentFile(fname)
```

```
title: StudentsPerformance.csv, id: 1--kPVRX5KpOLhIJi5Gj7jyEo13eEZ_q3
downloading to /root/data/StudentsPerformance.csv
```

2.3.2. Определение основных характеристик датасета

In [0]:
```
!pip install -U seaborn
```

```
Requirement already up-to-date: seaborn in /usr/local/lib/python3.6/dist-packages (0.9.0)
Requirement already satisfied, skipping upgrade: matplotlib>=1.4.3 in /usr/local/lib/python3.6/
Requirement already satisfied, skipping upgrade: numpy>=1.9.3 in /usr/local/lib/python3.6/dist-
Requirement already satisfied, skipping upgrade: scipy>=0.14.0 in /usr/local/lib/python3.6/dist-
Requirement already satisfied, skipping upgrade: pandas>=0.15.2 in /usr/local/lib/python3.6/dis
Requirement already satisfied, skipping upgrade: kiwisolver>=1.0.1 in /usr/local/lib/python3.6/d
Requirement already satisfied, skipping upgrade: pyparsing!=2.0.4,!=2.1.2,!=2.1.6,>=2.0.1 in /us
Requirement already satisfied, skipping upgrade: cycler>=0.10 in /usr/local/lib/python3.6/dist-p
Requirement already satisfied, skipping upgrade: python-dateutil>=2.1 in /usr/local/lib/python3
Requirement already satisfied, skipping upgrade: pytz>=2011k in /usr/local/lib/python3.6/dist-p
Requirement already satisfied, skipping upgrade: setuptools in /usr/local/lib/python3.6/dist-pack
Requirement already satisfied, skipping upgrade: six in /usr/local/lib/python3.6/dist-packages (fr
```

In [0]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

In [0]:
```
data = pd.read_csv(fname, sep=",")
```

In [0]:
```
data.head()
```

Out[0]:

	gender	race/ethnicity	parental level of education	lunch	test preparation course	math score	reading score	writing score
0	female	group B	bachelor's degree	standard	none	72	72	74
1	female	group C	some college	standard	completed	69	90	88
2	female	group B	master's degree	standard	none	90	95	93
3	male	group A	associate's degree	free/reduced	none	47	57	44
4	male	group C	some college	standard	none	76	78	75

In [0]:
```
total_count = data.shape[0]
print('Всего строк: {}'.format(total_count))
```

```
Всего строк: 1000
```

In [0]:
```
# Список колонок с типами данных
data.dtypes
```

Out[0]:
```
gender                         object
race/ethnicity                 object
parental level of education    object
lunch                          object
test preparation course        object
math score                      int64
reading score                   int64
writing score                   int64
dtype: object
```

In [0]:
```
# Проверка наличия пустых значений
for col in data.columns:
    # Количество пустых значений - все значения заполнены
    temp_null_count = data[data[col].isnull()].shape[0]
    print('{} - {}'.format(col, temp_null_count))
```

```
gender - 0
race/ethnicity - 0
parental level of education - 0
lunch - 0
test preparation course - 0
math score - 0
reading score - 0
writing score - 0
```

In [0]:
```
# Основные статистические характеристки набора данных
data.describe()
```

Out[0]:

	math score	reading score	writing score
count	1000.00000	1000.000000	1000.000000
mean	66.08900	69.169000	68.054000
std	15.16308	14.600192	15.195657
min	0.00000	17.000000	10.000000
25%	57.00000	59.000000	57.750000
50%	66.00000	70.000000	69.000000
75%	77.00000	79.000000	79.000000
max	100.00000	100.000000	100.000000

In [0]:
```
# Выделим категориальные признаки
categorical_columns = [c for c in data.columns if data[c].dtype.name == 'object']
# Для каждого выделим его возможные значения
for col in categorical_columns:
  print(col + ": ", end="|")
  for unique_val in data[col].unique():
    print(unique_val, end="|")
  print()
```

```
gender: |female|male|
race/ethnicity: |group B|group C|group A|group D|group E|
parental level of education: |bachelor's degree|some college|master's degree|associate's degree|high
lunch: |standard|free/reduced|
test preparation course: |none|completed|
```

2.3.3. Диаграммы рассеяния

In [0]:
```
fig, ax = plt.subplots(figsize=(10,10))
sns.scatterplot(ax=ax, x='reading score', y='writing score', data=data)
```

Out[0]: <matplotlib.axes._subplots.AxesSubplot at 0x7f2cf70789b0>

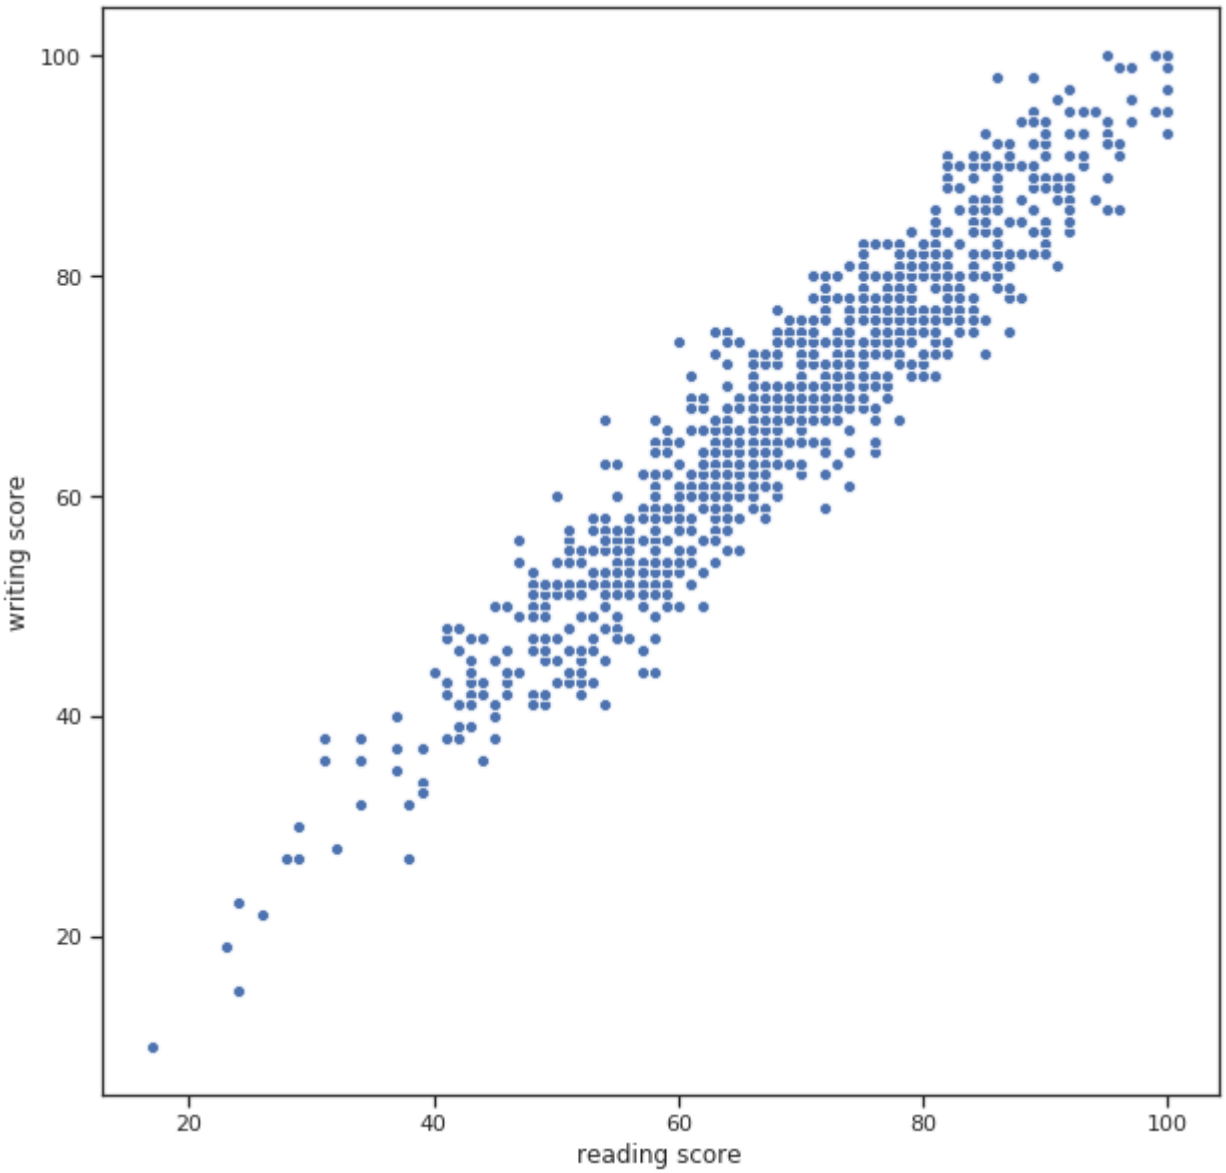

In [0]: fig, ax = plt.subplots(figsize=(10,10))
sns.scatterplot(ax=ax, x='reading score', y='writing score', data=data, hue='test preparati

Out[0]: <matplotlib.axes._subplots.AxesSubplot at 0x7f2cf6fd1780>

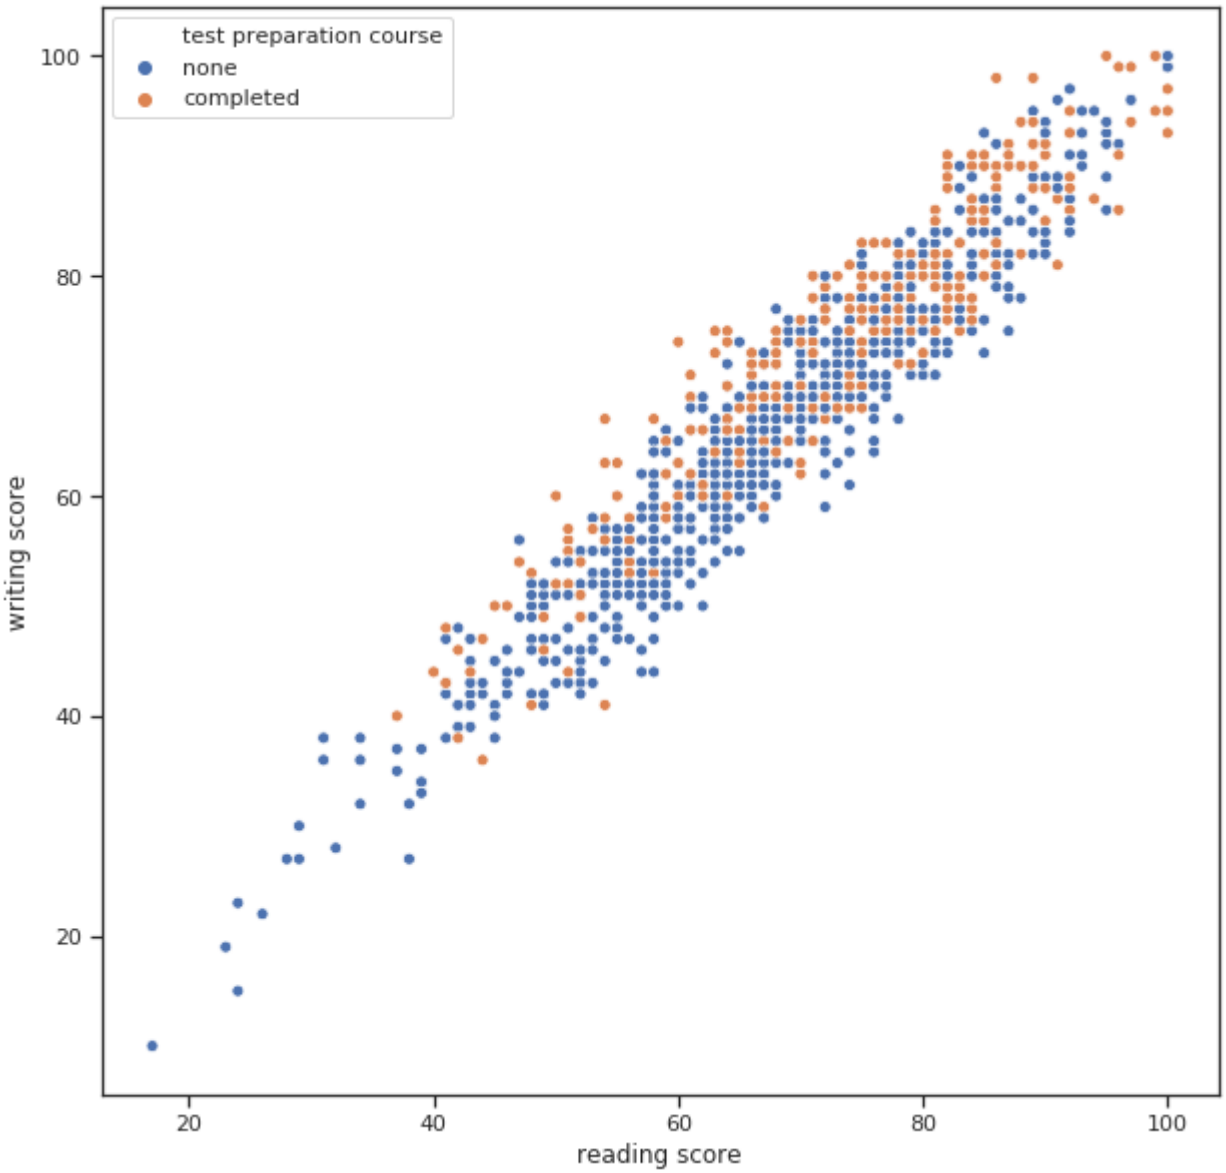

2.3.4. Гистограмма

In [0]: fig, ax = plt.subplots(figsize=(10,10))
sns.distplot(data['math score'])

Out[0]: <matplotlib.axes._subplots.AxesSubplot at 0x7f2cf6ee1198>

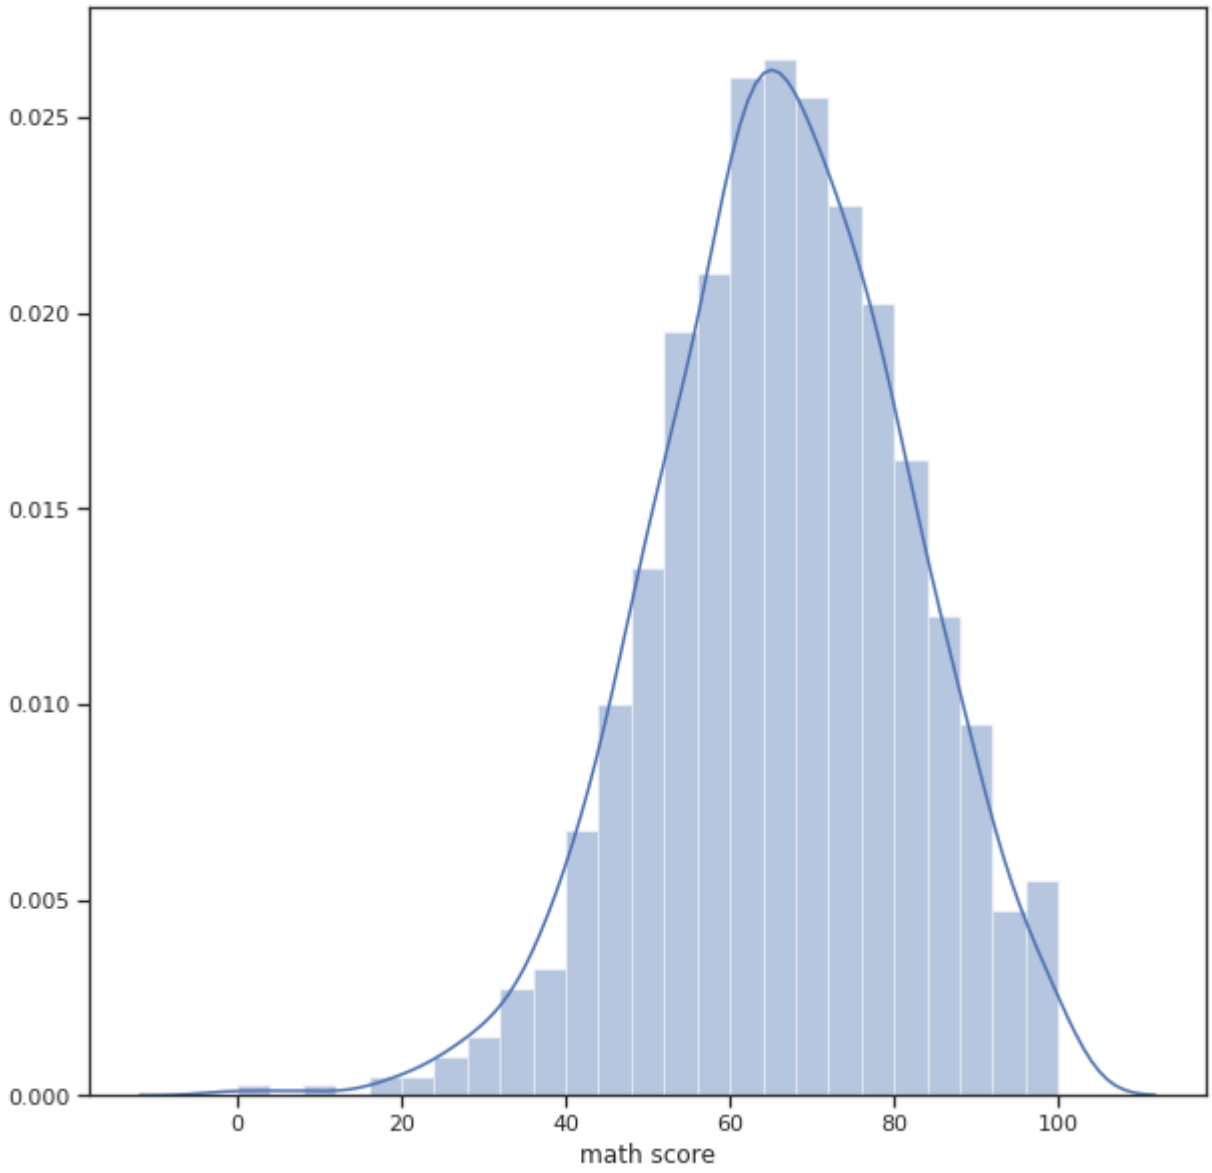

2.3.5. Jointplot

In [0]: sns.jointplot(x='math score', y='writing score', data=data)

Out[0]: <seaborn.axisgrid.JointGrid at 0x7f2cf53cf518>

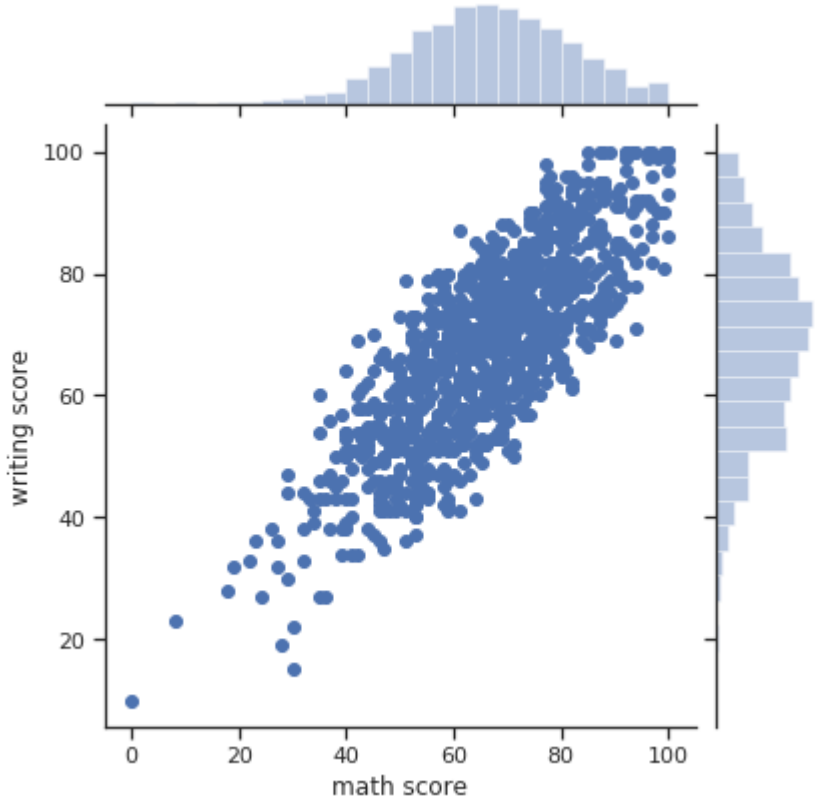

In [0]: sns.jointplot(x='math score', y='reading score', data=data, kind="hex")

Out[0]: <seaborn.axisgrid.JointGrid at 0x7f2cf5252400>

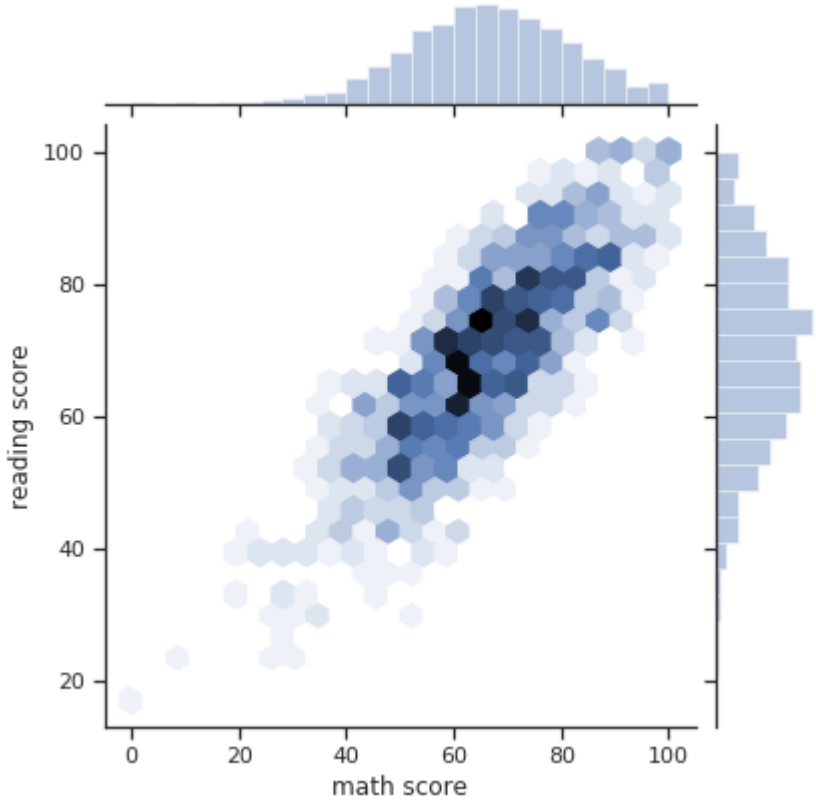

In [0]: sns.jointplot(x='writing score', y='reading score', data=data, kind="kde")

Out[0]: <seaborn.axisgrid.JointGrid at 0x7f2cf50df780>

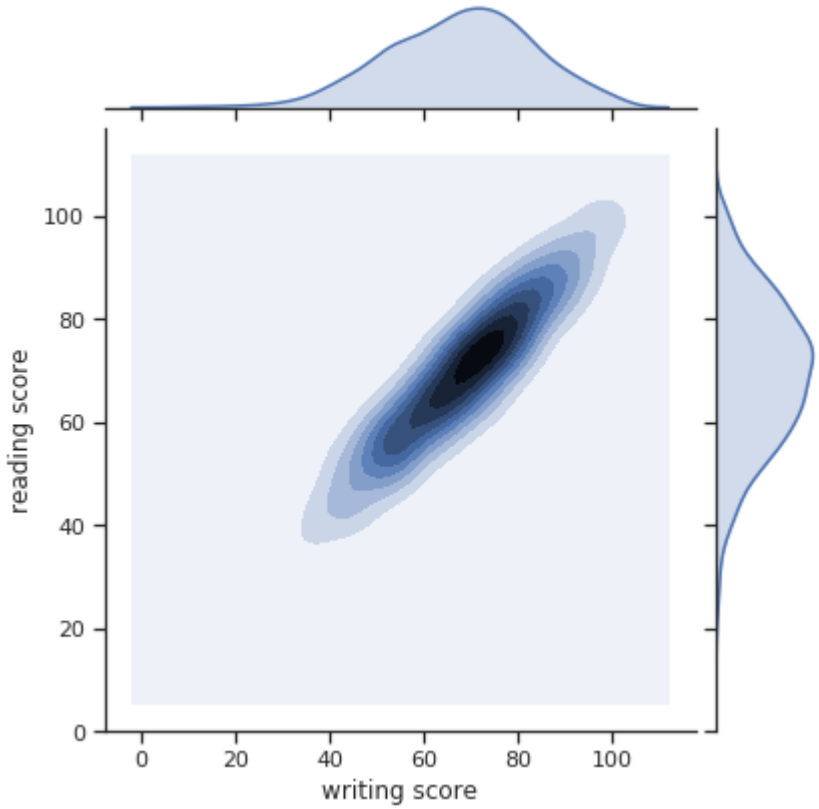

2.3.6. Парные диаграммы

In [0]: sns.pairplot(data)

Out[0]: <seaborn.axisgrid.PairGrid at 0x7f2cf50df908>

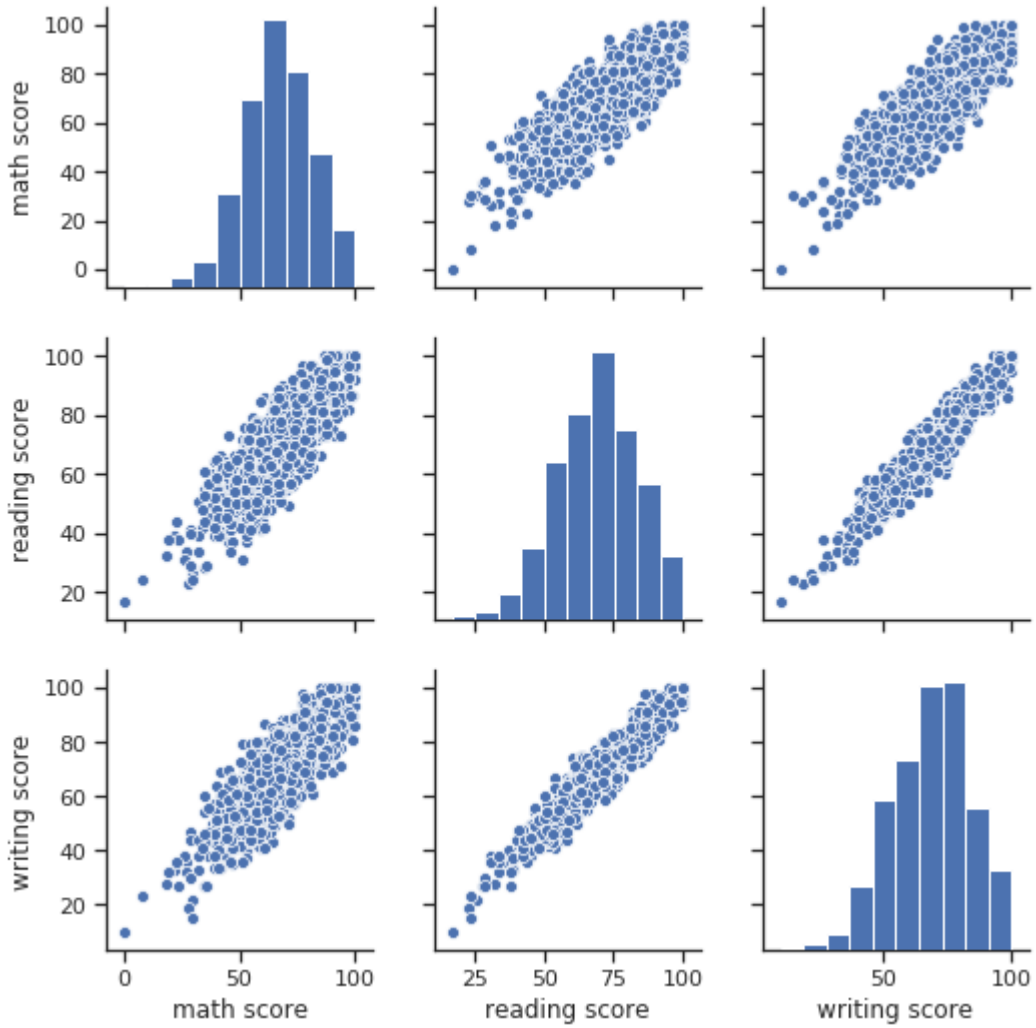

In [0]: sns.pairplot(data, hue="gender")

Out[0]: <seaborn.axisgrid.PairGrid at 0x7f2cf42e14a8>

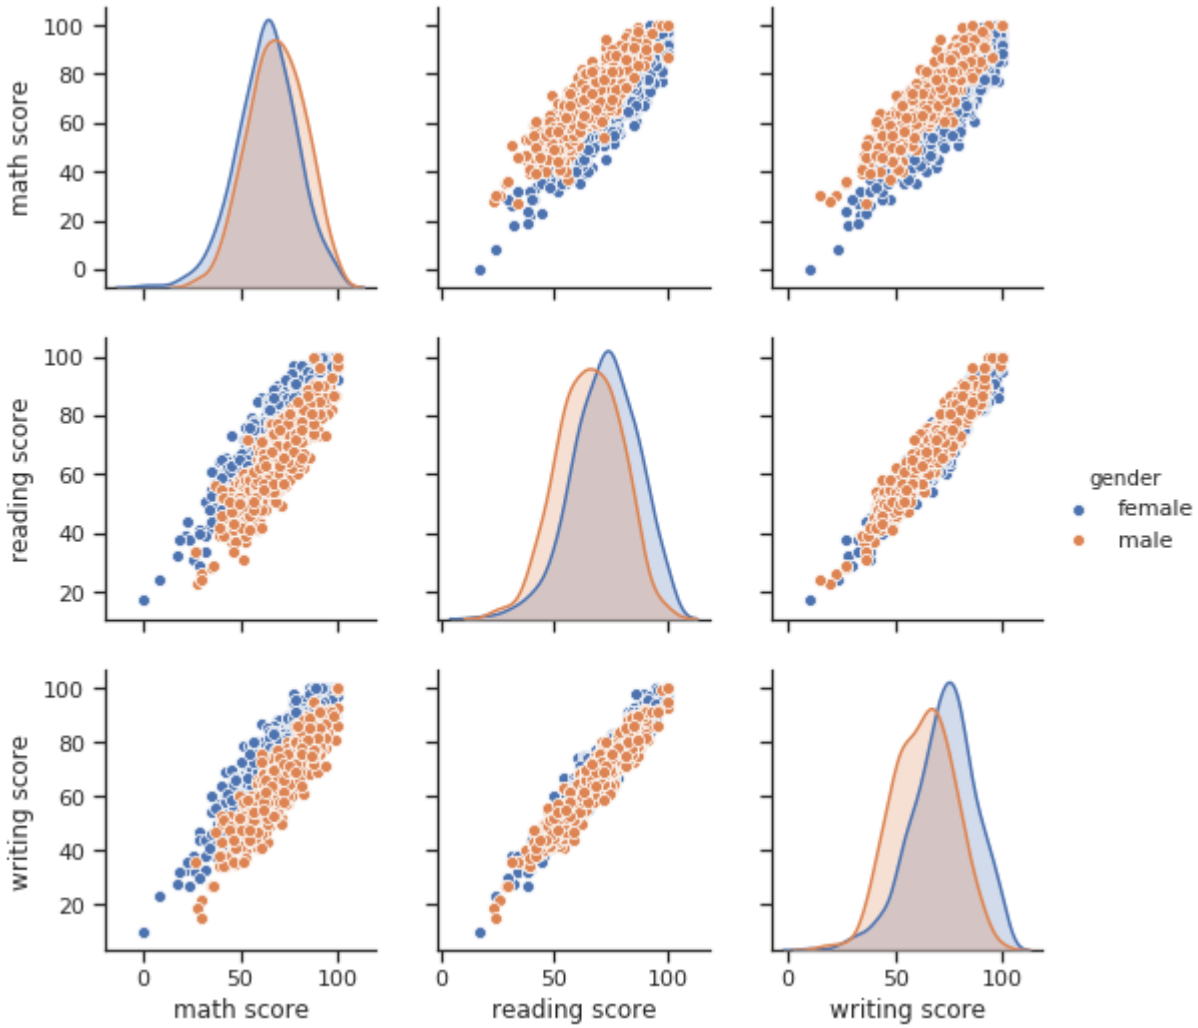

2.3.7. ”Ящик с усами”

In [0]: sns.boxplot(x=data['math score'])

Out[0]: <matplotlib.axes._subplots.AxesSubplot at 0x7f2cf3e909e8>

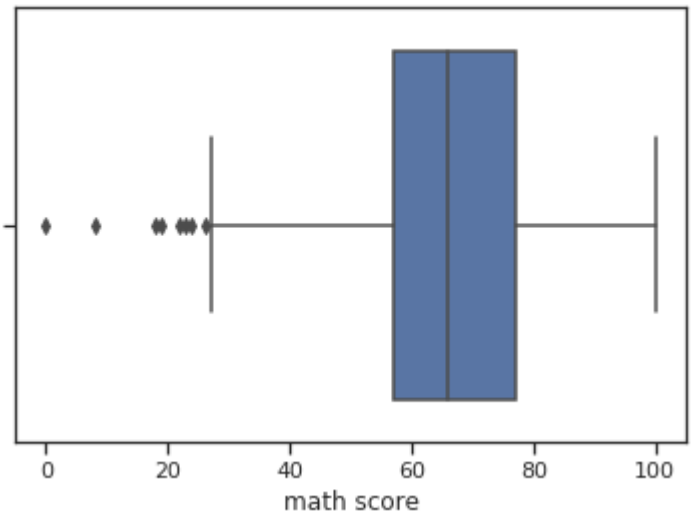

In [0]: sns.boxplot(y=data['math score'])

Out[0]: <matplotlib.axes._subplots.AxesSubplot at 0x7f2cf3e2b588>

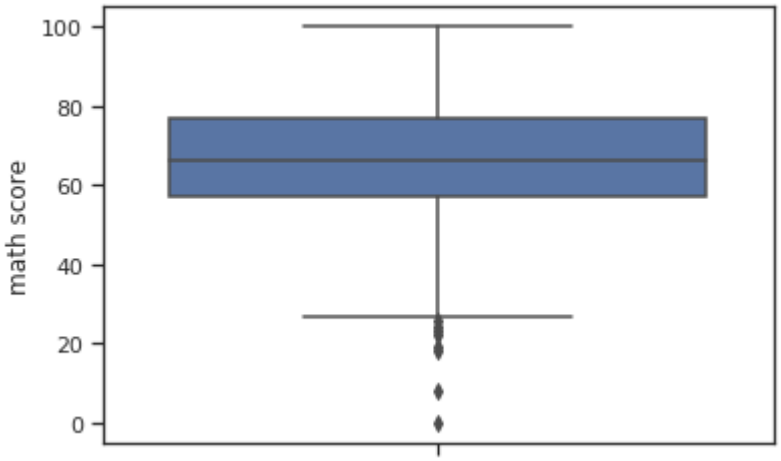

In [0]: sns.boxplot(x='gender', y='math score', data=data)

Out[0]: <matplotlib.axes._subplots.AxesSubplot at 0x7f2cf3de8588>

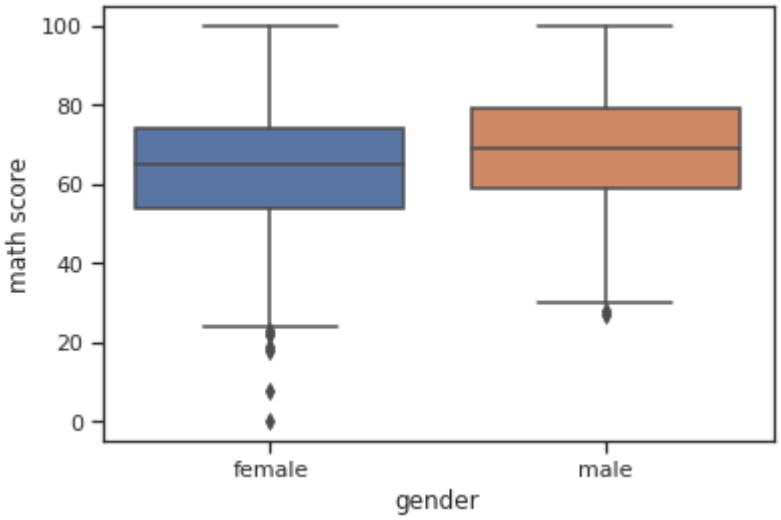

2.3.8. ViolinPlot

"Ящик с усами + распределение плотности"

```
In [0]: fig, ax =  plt.subplots(2, 1, figsize=(10,10))
        sns.violinplot(ax=ax[0], x=data['math score'])
        sns.distplot(data['math score'], ax=ax[1])
```

Out[0]: <matplotlib.axes._subplots.AxesSubplot at 0x7f2cf3bd7a90>

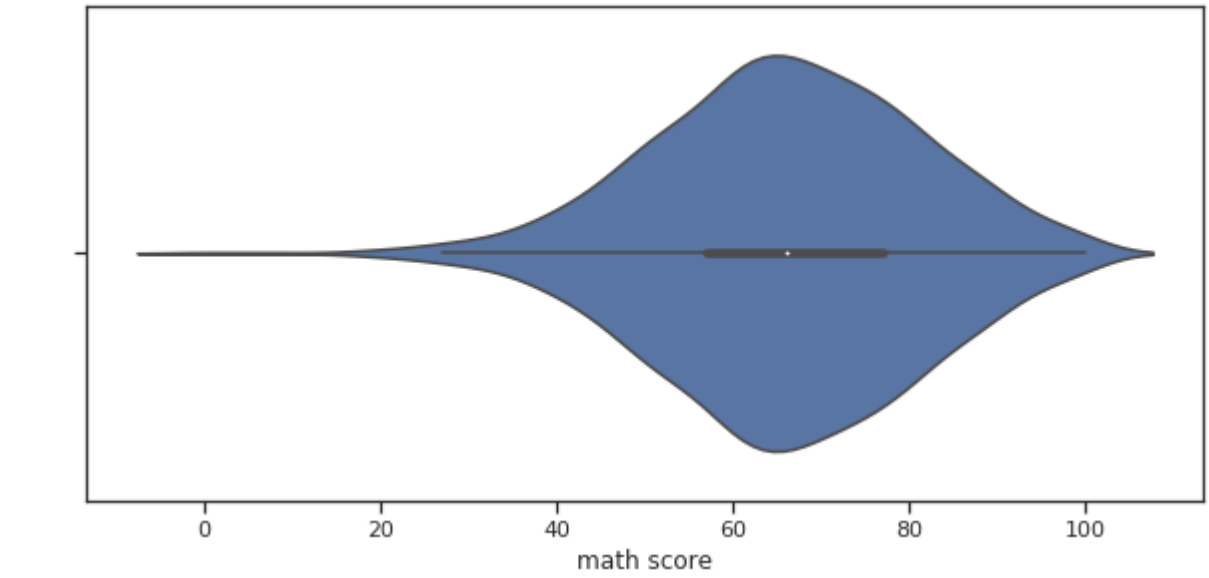

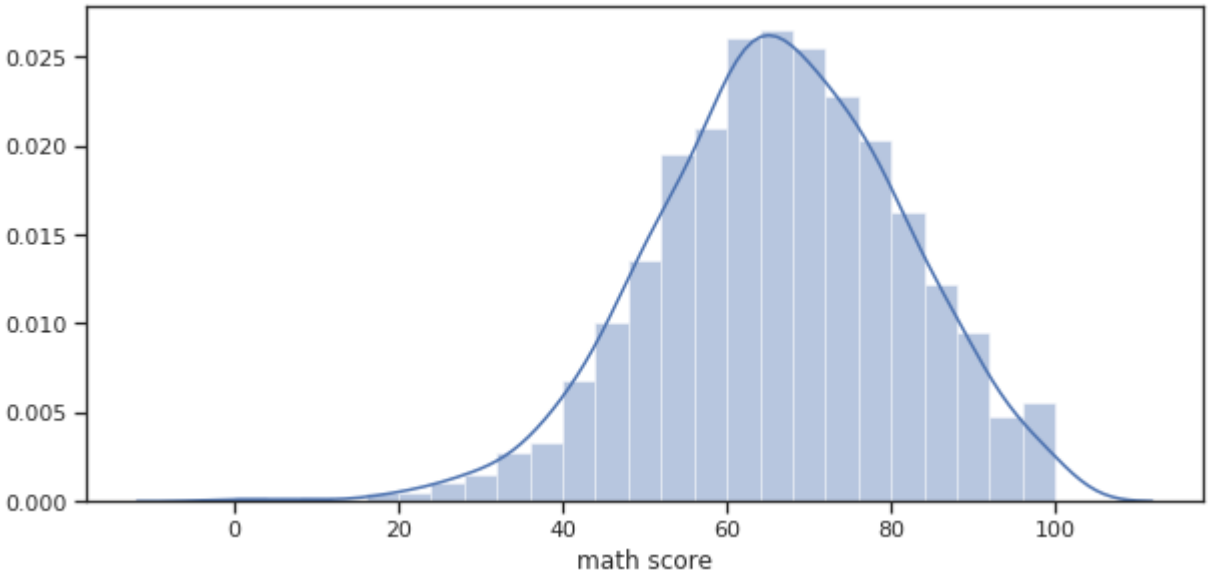

2.4. 4. Информация о корреляции признаков.

2.4.1. Корреляционные матрицы

In [0]: data.corr(method='pearson')

Out[0]:

	math score	reading score	writing score
math score	1.000000	0.817580	0.802642
reading score	0.817580	1.000000	0.954598
writing score	0.802642	0.954598	1.000000

In [0]: data.corr(method='kendall')

Out[0]:

	math score	reading score	writing score
math score	1.000000	0.617432	0.591067

reading score	0.617432	1.000000	0.820058
writing score	0.591067	0.820058	1.000000

In [0]: data.corr(method='spearman')

Out[0]:

	math score	reading score	writing score
math score	1.000000	0.804064	0.778339
reading score	0.804064	1.000000	0.948953
writing score	0.778339	0.948953	1.000000

In [0]: sns.heatmap(data.corr())

Out[0]: <matplotlib.axes._subplots.AxesSubplot at 0x7f2cf3893a58>

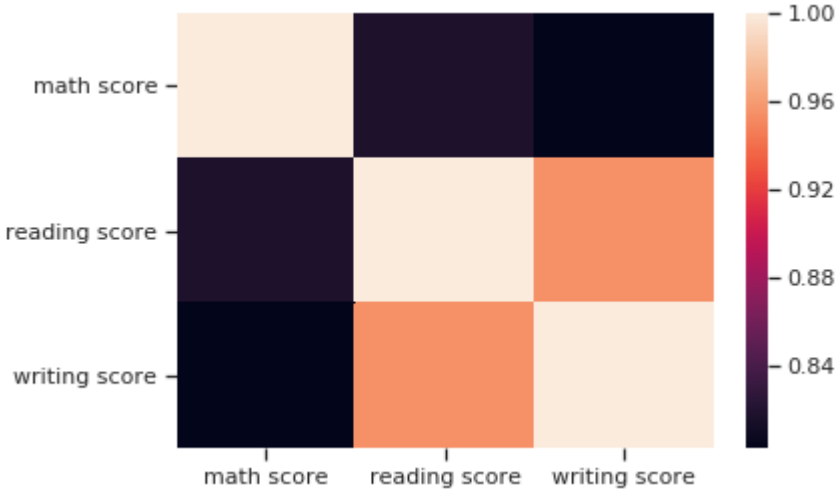

In [0]: sns.heatmap(data.corr(), annot=True, fmt='.3f')

Out[0]: <matplotlib.axes._subplots.AxesSubplot at 0x7f2cf287c2e8>

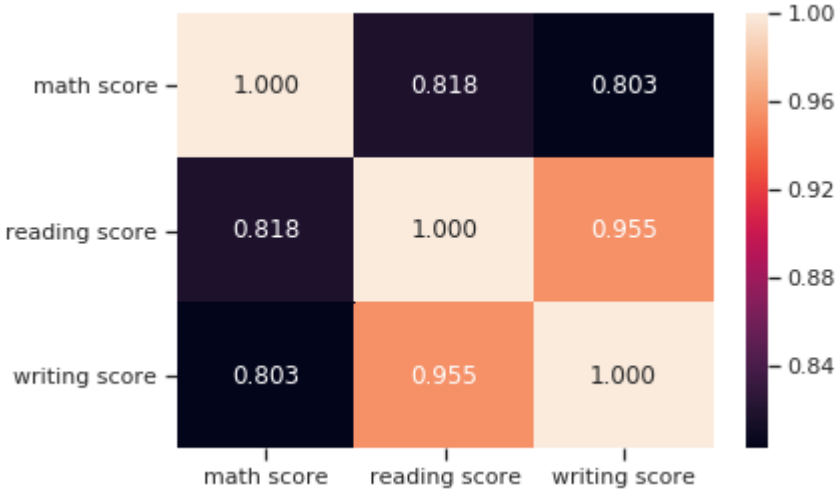

In [0]: sns.heatmap(data.corr(), cmap='YlGnBu', annot=True, fmt='.3f')

Out[0]: <matplotlib.axes._subplots.AxesSubplot at 0x7f2cf2798a20>

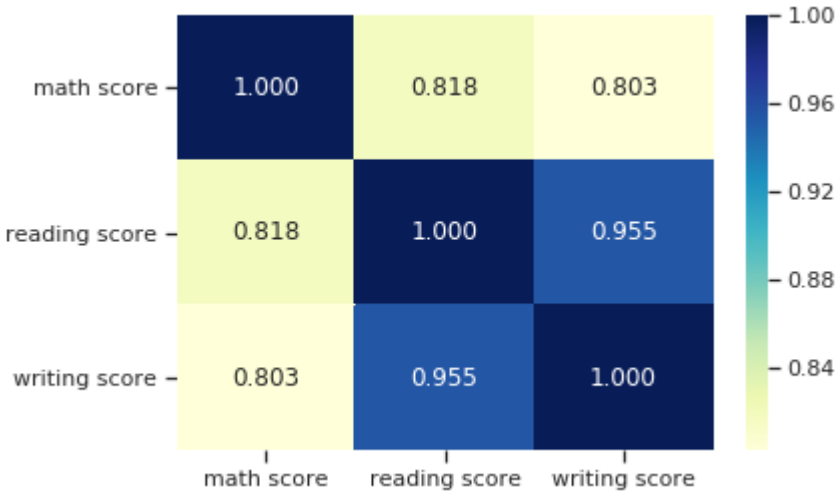

In [0]:
```
# Треугольный вариант матрицы
mask = np.zeros_like(data.corr(), dtype=np.bool)
# чтобы оставить нижнюю часть матрицы
# mask[np.triu_indices_from(mask)] = True
# чтобы оставить верхнюю часть матрицы
mask[np.tril_indices_from(mask)] = True
sns.heatmap(data.corr(), mask=mask, annot=True, fmt='.3f')
```

Out[0]: <matplotlib.axes._subplots.AxesSubplot at 0x7f2cf2726630>

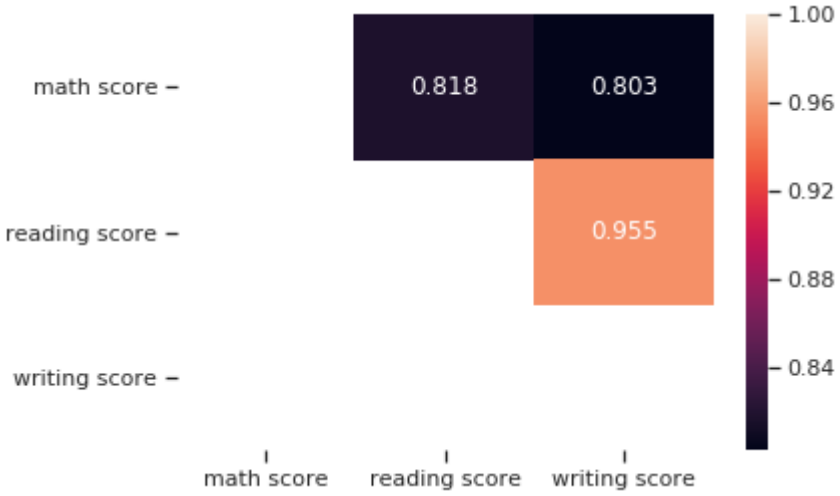

In [0]:
```
fig, ax = plt.subplots(1, 3, sharex='col', sharey='row', figsize=(15,5))
sns.heatmap(data.corr(method='pearson'), ax=ax[0], annot=True, fmt='.2f')
```

```
sns.heatmap(data.corr(method='kendall'), ax=ax[1], annot=True, fmt='.2f')
sns.heatmap(data.corr(method='spearman'), ax=ax[2], annot=True, fmt='.2f')
fig.suptitle('Корреляционные матрицы, построенные различными методами')
ax[0].title.set_text('Pearson')
ax[1].title.set_text('Kendall')
ax[2].title.set_text('Spearman')
```