Лабораторная работа 5 по дисциплине «Методы машинного обучения» на тему «Линейные модели, SVM и деревья решений.»

Выполнил: студент группы ИУ5-21М Могильников И. А.

1. Описание задания

Цель лабораторной работы: изучение линейных моделей, SVM и деревьев решений.

1.1. Задание

- 1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- 4. Обучите 1) одну из линейных моделей, 2) SVM и 3) дерево решений. Оцените качество моделей с помощью трех подходящих для задачи метрик. Сравните качество полученных моделей.
- 5. Произведите для каждой модели подбор одного гиперпараметра с использованием GridSearchCV и кросс-валидации.
- 6. Повторите пункт 4 для найденных оптимальных значений гиперпараметров. Сравните качество полученных моделей с качеством моделей, полученных в пункте 4.

2. Ход выполнения лабораторной работы

2.1. Выбор датасета

В качестве исходных данных выбираем датасет Heart Disease UCI (https://www.kaggle.com/ronitf/heart-disease-uci). 303 записи, 14 признаков, целевой признак относится к наличию болезни сердца у пациента: 0 - нет болезни сердца, 1 - есть.

```
In [0]: from google.colab import drive, files drive.mount('/content/drive')
```

Go to this URL in a browser: https://accounts.google.com/o/oauth2/auth?client id=9473189898

```
Enter your authorization code:
```

Mounted at /content/drive

```
In [0]: total count = data.shape[0]
      num cols = []
      for col in data.columns:
         # Количество пустых значений
         temp null count = data[data[col].isnull()].shape[0]
         dt = str(data[col].dtype)
         if temp_null_count>0:
            num cols.append(col)
            temp perc = round((temp null count / total count) * 100.0, 2)
            print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'
                 .format(col, dt, temp_null_count, temp_perc))
      data cleared = data
In [0]: uniquevalues = np.unique(data cleared['target'].values)
      uniquevalues
Out[0]: array([0, 1])
2.2. train test split
In [0]: target = data cleared['target']
      data_cleared = data_cleared.drop('target', axis=1)
In [0]: data cleared.head(10)
Out[0]:
          age sex cp trestbps chol fbs restecg thalach exang oldpeak slope \
      0
         63
               1
                  3
                         145
                              233
                                     1
                                            0
                                                  150
                                                          0
                                                               2.3
      1
         37
               1
                  2
                         130
                              250
                                     0
                                            1
                                                  187
                                                          0
                                                               3.5
                                                                       0
      2
         41
                  1
                              204
                                            0
                                                               1.4
                                                                       2
              0
                         130
                                     0
                                                  172
                                                          0
                                                                       2
      3
         56
               1
                  1
                         120
                              236
                                            1
                                                               0.8
                                    0
                                                  178
                                                          0
         57
                                                                       2
      4
              0
                  0
                         120
                              354
                                    0
                                            1
                                                  163
                                                          1
                                                               0.6
         57
      5
               1
                  0
                         140
                              192
                                    0
                                            1
                                                  148
                                                          0
                                                               0.4
                                                                       1
      6
         56
              0
                 1
                         140
                              294
                                    0
                                            0
                                                  153
                                                          0
                                                               1.3
                                                                       1
      7
         44
              1
                  1
                         120
                              263
                                    0
                                            1
                                                  173
                                                          0
                                                               0.0
                                                                       2
         52
                  2
                                                                       2
      8
               1
                         172
                              199
                                     1
                                            1
                                                  162
                                                          0
                                                               0.5
      9
         57
               1
                  2
                              168
                                            1
                                                                       2
                         150
                                     0
                                                  174
                                                          0
                                                               1.6
        ca thal
      0
         0
              1
         0
              2
      1
      2
              2
         0
              2
      3
         0
              2
      4
         0
              1
      5
         0
              2
      6
         0
      7
              3
         0
      8
         0
              3
      9
         0
              2
In [0]: from sklearn.model selection import train test split
      X train, X test, Y train, Y test = train test split(
```

```
data cleared,
         target,
         test size=0.2,
         random state=1
In [0]: X train.shape, Y_train.shape
Out[0]: ((242, 13), (242,))
In [0]: X test.shape, Y test.shape
Out[0]: ((61, 13), (61,))
2.3. Обучение
In [0]: from sklearn.linear model import SGDClassifier
      from sklearn.svm import LinearSVC
      from sklearn.tree import DecisionTreeClassifier
      from sklearn.model selection import GridSearchCV
      from sklearn.metrics import accuracy score
      from sklearn.metrics import balanced_accuracy_score
      from sklearn.metrics import precision score, recall score, f1 score
2.3.1. Стохастический градиентный спуск
In [0]: sgd = SGDClassifier().fit(X train, Y train)
     predicted sgd = sgd.predict(X test)
/usr/local/lib/python3.6/dist-packages/sklearn/linear_model/stochastic_gradient.py:166: Future
 FutureWarning)
In [0]: accuracy score(Y test, predicted sgd)
Out[0]: 0.5081967213114754
In [0]: balanced accuracy score(Y test, predicted sgd)
Out[0]: 0.5161290322580645
In [0]: (precision score(Y test, predicted sgd, average='weighted'),
      recall score(Y test, predicted sgd, average='weighted'))
Out[0]: (0.7540983606557377, 0.5081967213114754)
In [0]: f1 score(Y test, predicted sgd, average='weighted')
Out[0]: 0.35963114754098363
```

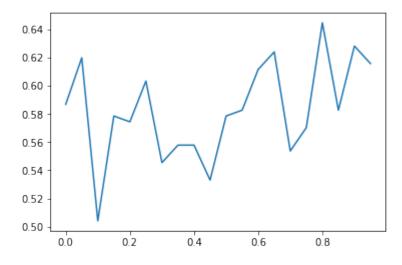
```
2.3.2. Линейный классификатор на основе SVM
In [0]: svm = LinearSVC(C=1.0).fit(X train, Y train)
     predicted sym = sym.predict(X test)
/usr/local/lib/python3.6/dist-packages/sklearn/svm/base.py:931: ConvergenceWarning: Liblinear
 "the number of iterations.", ConvergenceWarning)
In [0]: accuracy_score(Y test, predicted svm)
Out[0]: 0.7704918032786885
In [0]: balanced accuracy score(Y test, predicted svm)
Out[0]: 0.7677419354838709
In [0]: (precision score(Y test, predicted sym, average='weighted'),
      recall score(Y test, predicted svm, average='weighted'))
Out[0]: (0.8020791683326669, 0.7704918032786885)
In [0]: f1 score(Y test, predicted sym, average='weighted')
Out[0]: 0.7634790528233151
2.3.3. Дерево решений
In [0]: dt = DecisionTreeClassifier(random state=1).fit(X train, Y train)
     predicted dt = dt.predict(X test)
In [0]: accuracy score(Y test, predicted dt)
Out[0]: 0.6885245901639344
In [0]: balanced accuracy score(Y test, predicted dt)
Out[0]: 0.6887096774193548
In [0]: (precision score(Y test, predicted dt, average='weighted'),
      recall score(Y test, predicted dt, average='weighted'))
Out[0]: (0.6888947646747752, 0.6885245901639344)
In [0]: f1 score(Y test, predicted dt, average='weighted')
Out[0]: 0.6885245901639343
```

Из двух представленных моделей с параметрами по умолчанию с задачей классификации на выбранном датасете лучше справляется линейный классификатор на основе SVM.

2.4. Подбор гиперпараметров

2.4.1. Стохастический градиентный спуск

```
In [0]: n range = np.array(range(0,100,5))
              n_range = n_range / 100
              tuned parameters = [{'ll ratio': n range}]
              tuned parameters
Out[0]: [{'11_ratio': array([0., 0.05, 0.1, 0.15, 0.2, 0.25, 0.3, 0.35, 0.4, 0.45, 0.5,
                               0.55, 0.6, 0.65, 0.7, 0.75, 0.8, 0.85, 0.9, 0.95])
In [0]: import warnings
               warnings.filterwarnings('ignore')
              clf gs sgd = GridSearchCV(SGDClassifier(), tuned parameters, cv=5,
                                                      scoring='accuracy')
              clf gs sgd.fit(X train, Y train)
Out[0]: GridSearchCV(cv=5, error_score='raise-deprecating',
                           estimator=SGDClassifier(alpha=0.0001, average=False, class_weight=None,
                           early_stopping=False, epsilon=0.1, eta0=0.0, fit_intercept=True,
                           11 ratio=0.15, learning rate='optimal', loss='hinge', max iter=None,
                           n iter=None, n iter no change=5, n jobs=None, penalty='l2',
                           power t=0.5, random state=None, shuffle=True, tol=None,
                           validation fraction=0.1, verbose=0, warm start=False),
                           fit_params=None, iid='warn', n_jobs=None,
                           param grid=[{'l1 ratio': array([0., 0.05, 0.1, 0.15, 0.2, 0.25, 0.3, 0.35, 0.4, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45, 0.45
                           0.55, 0.6, 0.65, 0.7, 0.75, 0.8, 0.85, 0.9, 0.95])
                           pre dispatch='2*n jobs', refit=True, return train score='warn',
                           scoring='accuracy', verbose=0)
In [0]: clf gs sgd.best params
Out[0]: {'l1_ratio': 0.8}
In [0]: plt.plot(n_range, clf_gs_sgd.cv_results_['mean_test_score'])
Out[0]: [<matplotlib.lines.Line2D at 0x7f3fe94ec048>]
```



2.4.2. Линейный классификатор на основе SVM

```
In [0]: n_range = np.array(range(1,20,1))
tuned_parameters = [{'C': n_range}]
tuned_parameters
```

Out[0]: [{'C': array([1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19])}]

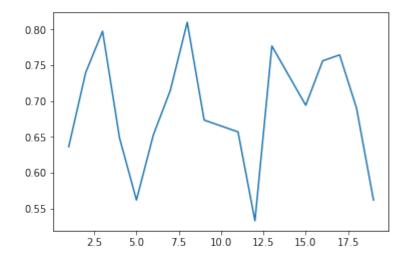
In [0]: clf_gs_svm = GridSearchCV(LinearSVC(), tuned_parameters, cv=3, scoring='accuracy')
clf_gs_svm.fit(X_train, Y_train)

In [0]: clf gs sym.best params

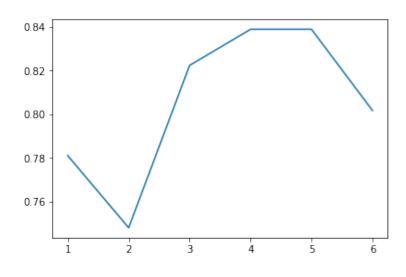
Out[0]: {'C': 8}

 $In \ [0]: plt.plot(n_range, clf_gs_svm.cv_results_['mean_test_score'])$

Out[0]: [<matplotlib.lines.Line2D at 0x7f3fe94c5dd8>]



```
2.4.3. Дерево решений
In [0]: n range = np.array(range(1,7,1))
      tuned_parameters = [\{'max_depth': n_range\}]
     tuned parameters
Out[0]: [\{\text{max depth': array}([1, 2, 3, 4, 5, 6])\}]
In [0]: clf gs dt = GridSearchCV(DecisionTreeClassifier(random state=1), tuned parameters,
                         cv=5, scoring='accuracy')
     clf gs dt.fit(X train, Y train)
Out[0]: GridSearchCV(cv=5, error score='raise-deprecating',
           estimator=DecisionTreeClassifier(class weight=None, criterion='gini', max depth=None
              max_features=None, max_leaf_nodes=None,
              min impurity decrease=0.0, min impurity split=None,
              min samples leaf=1, min samples split=2,
              min weight fraction leaf=0.0, presort=False, random state=1,
              splitter='best'),
           fit_params=None, iid='warn', n_jobs=None,
           param\_grid = [\{'max\_depth': array([1, 2, 3, 4, 5, 6])\}],
          pre dispatch='2*n jobs', refit=True, return train score='warn',
          scoring='accuracy', verbose=0)
In [0]: clf gs dt.best params
Out[0]: {'max depth': 4}
In [0]: plt.plot(n range, clf gs dt.cv results ['mean test score'])
```



Out[0]: [<matplotlib.lines.Line2D at 0x7f3fe9368dd8>]

```
2.5. Сравнение моделей после подбора гиперпараметров
2.5.1. Стохастический градиентный спуск
In [0]: sgd_optimized = SGDClassifier(l1_ratio=clf_gs_sgd.best_params_['l1_ratio']).fit(X_tra
     predicted sgd opt = sgd optimized.predict(X test)
In [0]: accuracy score(Y test, predicted sgd opt)
Out[0]: 0.5409836065573771
In [0]: balanced accuracy score(Y test, predicted sgd opt)
Out[0]: 0.5338709677419355
In [0]: (precision score(Y test, predicted sgd opt, average='weighted'),
      recall score(Y test, predicted sgd opt, average='weighted'))
Out[0]: (0.6363244176013804, 0.5409836065573771)
In [0]: f1 score(Y test, predicted sgd opt, average='weighted')
Out[0]: 0.4332865784167616
2.5.2. Линейный классификатор на основе SVM
In [0]: svm_optimized = LinearSVC(C=clf_gs_svm.best_params_['C']).fit(X_train, Y_train)
     predicted sym opt = sym optimized.predict(X test)
In [0]: accuracy score(Y test, predicted sym opt)
Out[0]: 0.6885245901639344
In [0]: balanced accuracy score(Y test, predicted sym opt)
Out[0]: 0.68333333333333333
In [0]: (precision score(Y test, predicted sym opt, average='weighted'),
      recall score(Y test, predicted sym opt, average='weighted'))
Out[0]: (0.8068852459016393, 0.6885245901639344)
In [0]: f1 score(Y test, predicted sym opt, average='weighted')
Out[0]: 0.6528845252022647
```

```
2.5.3. Дерево решений

In [0]: dt_optimized = DecisionTreeClassifier(max_depth=clf_gs_dt.best_params_['max_depth_predicted_dt_opt = dt_optimized.predict(X_test)

In [0]: accuracy_score(Y_test, predicted_dt_opt)

Out[0]: 0.7704918032786885

In [0]: balanced_accuracy_score(Y_test, predicted_dt_opt)

Out[0]: 0.7704301075268818

In [0]: (precision_score(Y_test, predicted_dt_opt, average='weighted'), recall_score(Y_test, predicted_dt_opt, average='weighted'))

Out[0]: (0.7704918032786885, 0.7704918032786885)

In [0]: f1_score(Y_test, predicted_dt_opt, average='weighted')

Out[0]: 0.7704918032786885
```

Подбор гиперпараметров позволил увеличить точность работы стохастического градиентного спуска и дерева решений. В случае с деревом решений, точность модели увеличилась существенно и после подбора гиперпараметров именно эта модель предоставляет наибольшую точность.